UNIVERSIDAD MAYOR DE SAN ANDRÉS
FACULTAD DE CIENCIAS PURAS Y NATURALES
CARRERA DE INFORMÁTICA



Análisis de sentimientos y emociones en el grupo de Telegram de Temporada 2026 de la Carrera de Informática

Integrantes: Univ. Chavez Gutierrez Eddy Yojan.
Univ. Copa Quispe Esther Sara.
Univ. Reyes Barja Carlos Eduardo.
Univ. Rojas Condori Fidel Angel.

Docente: M.Sc. Menfy Morales Rios.

Materia: Minería De Datos (Data Mining).

Sigla: INF-311.

Fecha: 28 de octubre de 2026.

Resumen ejecutivo 5
Introducción 5
Planteamiento del problema 6
Objetivos 7
Objetivo general 7
Objetivos específicos 7
Alcance, privacidad y ética 7
Marco conceptual 8
Minería de texto 8
Polaridad 8
Emociones y clasificación multietiqueta 8
Diccionario contextual 9
TF-IDF 9
Embeddings MiniLM 9
Modelo híbrido 10
Métricas 10
Kappa de Cohen 10
Precisión, recall y F1 10
Datos utilizados 11
Resumen 11
Distribución de la muestra por gestión 11
Metodología 11
Extracción y pseudonimización 13
Preprocesamiento 13
Diccionario y cobertura 13
Muestreo 14
Anotación manual 14
Validación y adjudicación 14
Modelado 15
Validación cruzada sin fuga de información 15
Bitácora de limpieza y transformación 15
Correspondencia con la metodología solicitada 16
1. Auditoría y perfilado inicial 16
2. Normalización de estructura y formatos 16
3. Gestión de duplicados 16
4. Tratamiento de valores faltantes 17

5. Detección y tratamiento de valores atípicos ... 17
6. Consistencia y reglas de negocio ... 17
Registro de auditoría aplicado ... 18
Trazabilidad automática de ejecuciones ... 20
Implementación: código esencial ... 20
Normalización de etiquetas ... 20
Creación reproducible de la muestra ... 20
Construcción del objetivo adjudicado ... 21
Agrupación de textos duplicados ... 21
TF-IDF y representación híbrida ... 21
Clasificador balanceado ... 22
Predicción multietiqueta ... 22
Protección de la salida final ... 22
Guía de los archivos CSV ... 23
Regla de lectura ... 23
corpus_anonimizado.csv ... 23
etiquetado_anotador_a.csv y etiquetado_anotador_b.csv ... 23
referencia_reglas_no_usar_al_etiquetar.csv ... 24
dataset_consenso_umsa.csv ... 24
desacuerdos_modelado.csv ... 24
dataset_modelado_umsa.csv ... 24
control_calidad.csv ... 25
comparacion_modelos.csv ... 25
metricas_por_fold.csv, resumen_folds.csv y metricas_por_clase.csv ... 25
predicciones_corpus.csv ... 25
Resultados ... 25
Calidad de la anotación ... 25
Distribución del dataset adjudicado ... 26
Comparación de modelos ... 27
Polaridad ... 27
Emociones multietiqueta ... 27
Interpretación ... 28
Matriz de confusión de polaridad ... 29
Desempeño por emoción ... 30
Clasificación del corpus completo ... 31
Polaridad predicha ... 31
Emociones predichas ... 32
Variación de polaridad por gestión ... 33

Confianza de las predicciones....33
Discusión....33
Limitaciones y amenazas a la validez....34
Conclusiones....34
Recomendaciones....35
Reproducibilidad....35
Estructura del proyecto....36
Archivos principales producidos....37
Evidencias visuales y capturas....37
Tokens frecuentes generados con el flujo de preprocesamiento....38
Puntaje auxiliar con syuzhet y léxico personalizado....39
Cobertura del diccionario contextual por gestión....39
Diagnóstico de mensajes que no activaron las reglas....40
Distribución del dataset humano utilizado en la etapa descriptiva....40
Comparación final de modelos mediante predicciones fuera de muestra....41
Pantalla de Inicio de la página....41
Dashboard de la página....42
Resumen ejecutivo....42
Polaridad....43
Modelos....43
Calidad y Límite....44
Referencias....44
Anexo: correspondencia entre scripts y etapas....44

Resumen ejecutivo

Este proyecto desarrolla un proceso reproducible de minería de texto para estudiar la polaridad y las emociones expresadas en el grupo de Telegram de Temporada 2026 de la Carrera de Informática. Aunque el nombre actual del grupo menciona 2026, la exportación conserva mensajes históricos desde el **16 de diciembre de 2022 hasta el 12 de octubre de 2026**. El corpus final contiene **21.546 mensajes de texto**.

El trabajo no se limitó a aplicar un diccionario. Se construyó un dataset propio de **1.085 mensajes**, etiquetado independientemente por dos anotadores y posteriormente adjudicado. A partir de esta referencia humana se compararon cinco alternativas:

1. baseline de clase mayoritaria o ausencia de emoción;
2. diccionario contextual de reglas;
3. regresión logística con TF-IDF;
4. regresión logística con embeddings MiniLM;
5. regresión logística con la representación híbrida TF-IDF + MiniLM.

La evaluación se realizó con validación cruzada de cinco particiones y agrupación por texto normalizado. Este diseño impide que dos mensajes idénticos aparezcan a la vez en entrenamiento y prueba. El modelo híbrido obtuvo el mejor resultado entre los modelos aprendidos: **macro-F1 de 0,393 para polaridad** y **0,375 para diez emociones**. Después se entrenó con las 1.085 etiquetas finales y se aplicó al corpus completo.

El resultado debe interpretarse como un análisis **exploratorio y agregado**. Las predicciones no constituyen diagnósticos psicológicos ni deben utilizarse para evaluar personas. Además, debido a que la muestra fue enriquecida con casos que contenían señales emocionales, las proporciones del dataset manual no representan directamente las proporciones del chat completo.

Palabras clave: minería de texto, análisis de sentimientos, emociones, Telegram, TF-IDF, embeddings, MiniLM, clasificación multietiqueta.

Introducción

Los grupos de mensajería instantánea se han convertido en un medio habitual de coordinación académica. En ellos se publican consultas, anuncios, horarios, recomendaciones, dificultades administrativas, agradecimientos y conversaciones sociales. La revisión manual de miles de mensajes es lenta y difícil de repetir; por ello, la minería de texto permite transformar el contenido no estructurado en variables y resúmenes que puedan analizarse de manera sistemática.

El análisis de sentimientos busca reconocer la orientación afectiva general de un texto. El análisis de emociones intenta identificar estados expresados de forma más específica, por ejemplo alegría, preocupación, tristeza o gratitud. Esta tarea es especialmente compleja en conversaciones reales porque aparecen abreviaciones, faltas ortográficas, modismos

locales, emojis, ironía, preguntas breves y mensajes que dependen de intervenciones anteriores.

Una palabra aislada tampoco determina necesariamente una emoción. Por ejemplo, una consulta puede contener la palabra "problema" sin expresar tristeza, y la frase "no está mal" incluye una palabra negativa dentro de una construcción posiblemente positiva. Debido a ello, el proyecto utiliza reglas interpretables como punto de partida, pero contrasta sus resultados con anotación humana y con modelos que representan el vocabulario y la semejanza semántica.

Planteamiento del problema

El corpus contiene mensajes de distinta longitud, propósito y grado de expresividad. Una gran cantidad corresponde a información o coordinación académica sin emoción explícita, mientras que otras publicaciones pueden expresar varias emociones a la vez. Un sistema basado únicamente en coincidencias de palabras puede:

- confundir una consulta neutral con preocupación;
- asignar polaridad a un anuncio puramente informativo;
- ignorar variaciones ortográficas y vocabulario local;
- perder el efecto de una negación;
- clasificar de forma incorrecta mensajes irónicos;
- forzar una sola emoción cuando coexisten varias.

La pregunta principal es:

> ¿Qué polaridades y emociones se expresan en el grupo de Telegram de Temporada de Informática, y qué tan bien pueden identificarse mediante reglas, TF-IDF y representaciones semánticas evaluadas contra un dataset humano propio?

Preguntas secundarias:

1. ¿Qué cobertura obtiene el diccionario original y cuánto mejora al adaptarlo al lenguaje del chat?
2. ¿Cuál es el nivel de acuerdo entre dos anotadores humanos?
3. ¿Los embeddings multilingües superan a una representación TF-IDF?
4. ¿La combinación de información léxica y semántica mejora el resultado?
5. ¿Qué clases son fáciles o difíciles de reconocer y por qué?

Objetivos

Objetivo general

Construir y evaluar un proceso reproducible de minería de texto y análisis de sentimientos para identificar polaridades, emociones y patrones agregados en el grupo de Telegram de Temporada de la Carrera de Informática.

Objetivos específicos

1. Extraer mensajes desde la exportación HTML de Telegram.
2. Pseudonimizar a los participantes y separar datos privados de resultados publicables.
3. Limpiar, normalizar y tokenizar el contenido textual.
4. Construir un diccionario contextual de sentimientos y medir su cobertura.
5. Diseñar una muestra estratificada que incluya emociones poco frecuentes y mensajes sin evidencia léxica.
6. Etiquetar manualmente polaridad, emociones, intensidad, tema e ironía mediante dos anotadores independientes.
7. Medir el acuerdo entre anotadores y adjudicar los desacuerdos.
8. Comparar reglas, TF-IDF, embeddings MiniLM y una representación híbrida.
9. Evaluar los modelos sin fuga de textos duplicados mediante validación cruzada.
10. Aplicar el mejor modelo al corpus completo y presentar resultados agregados.
11. Documentar el código, los CSV, las limitaciones y los pasos de reproducción.

Alcance, privacidad y ética

La unidad de análisis es cada mensaje textual. Se excluyeron eventos internos de Telegram y archivos multimedia que no contaban con transcripción. Los nombres se reemplazaron por códigos como `P001`, `P002`, etc. Esta medida es una **pseudonimización**, no una anonimización absoluta: el contenido de un mensaje podría conservar información identificable. Por ese motivo, los CSV que contienen texto o participante deben permanecer privados.

Las salidas destinadas a presentación no incluyen texto ni códigos de participante. Contienen solamente ID del mensaje, variables temporales, predicciones y valores de confianza. El análisis describe señales lingüísticas agregadas; no permite concluir cómo se siente realmente una persona ni efectuar diagnósticos psicológicos.

Principios aplicados:

- minimización de datos en las salidas;
- separación entre datos privados y resultados agregados;
- pseudonimización de participantes;
- ausencia de perfiles individuales;

- documentación de incertidumbre y limitaciones;
- uso académico y no disciplinario.

Marco conceptual

Minería de texto

La minería de texto convierte contenido no estructurado en representaciones analizables. El proceso suele incluir extracción, limpieza, tokenización, normalización, construcción de variables y aplicación de métodos descriptivos o predictivos. En este proyecto se generó además una matriz documento-término de **21.546 documentos y 10.421 términos**, con 117.268 celdas no nulas. Su dispersión es 0,99948, algo esperado porque cada mensaje utiliza solo una pequeña fracción del vocabulario total.

Polaridad

La polaridad resume la orientación global del mensaje. Se utilizaron seis clases:

Clase	Interpretación
`positiva`	Predomina una valoración o expresión favorable.
`negativa`	Predomina una valoración o expresión desfavorable.
`neutra`	Existe contenido emocional neutral o exploratorio.
`mixta`	Coexisten señales positivas y negativas.
`ambigua`	No es posible decidir con suficiente claridad.
`sin_sentimiento`	El mensaje es informativo o no contiene emoción explícita.

`neutra` y `sin_sentimiento` no son sinónimos. La primera reconoce una señal afectiva neutral, mientras que la segunda indica ausencia de evidencia emocional.

Emociones y clasificación multietiqueta

Una tarea multiclase selecciona una sola clase. En cambio, una tarea multietiqueta permite activar varias categorías simultáneamente. El proyecto conserva hasta dos emociones humanas por mensaje y modela diez categorías con al menos veinte casos:

1. admiración;
2. alegría;
3. confusión;
4. curiosidad;

5. decepción;
6. enojo;
7. esperanza;
8. gratitud;
9. preocupación;
10. tristeza.

El requisito de trabajar con ocho o más emociones queda cubierto con diez clases. Las categorías amor, tranquilidad, sorpresa, cansancio y vergüenza existen en el libro de códigos, pero no alcanzaron el soporte mínimo para un aprendizaje y una evaluación razonablemente estables.

Diccionario contextual

Un diccionario relaciona palabras, raíces, expresiones y emojis con emociones y polaridades. Su principal ventaja es la interpretabilidad: cada predicción puede rastrearse hasta una evidencia. Su principal limitación es que la coincidencia no comprende completamente el contexto.

Se partió de quince categorías del documento proporcionado por la materia y se añadieron variantes ortográficas, expresiones frecuentes del chat, emoticonos y emojis. La ampliación se documentó y se mantuvo separada de la anotación humana para evitar que las sugerencias automáticas sesgaran a los anotadores.

TF-IDF

TF-IDF pondera un término según dos factores:

- **TF:** frecuencia del término dentro del documento;
- **IDF:** rareza del término en el conjunto de documentos.

De forma simplificada:

$$TF - IDF\,(t,d) = TF(t,d) \times log\left(\frac{N}{DF\,(t)}\right)$$

En el proyecto se utilizaron unigramas y bigramas, `min_df=2`, un máximo de 30.000 características y escalamiento sublineal de la frecuencia. TF-IDF es útil para capturar vocabulario local, pero dos frases semánticamente parecidas pueden quedar lejos si no comparten palabras.

Embeddings MiniLM

Un embedding representa cada mensaje mediante un vector denso. Se utilizó `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2`, preparado para representar semejanza semántica en múltiples idiomas. Los vectores fueron normalizados y

el modelo preentrenado permaneció congelado. Sobre ellos se entrenó una regresión logística, una decisión apropiada para un dataset de tamaño limitado.

Los embeddings no son un diccionario creado desde cero por el proyecto: son una representación semántica preentrenada. El componente propio del trabajo está en el dataset humano, el diccionario contextual, la evaluación, la selección de clases y el entrenamiento de los clasificadores finales.

Modelo híbrido

La representación híbrida concatena ambas fuentes:

$$X_{híbrido} = [X_{TF-IDF} | X_{MiniLM}]$$

TF-IDF conserva palabras y expresiones propias del entorno universitario; MiniLM aporta información semántica. Una regresión logística balanceada aprende a combinar las dos representaciones.

Métricas

Kappa de Cohen

Mide acuerdo entre anotadores descontando el acuerdo esperado por azar:

$$\kappa = \frac{(p_o - p_e)}{(1 - p_e)}$$

donde p_o es el acuerdo observado y p_e el esperado. Kappa debe interpretarse junto con las distribuciones de clase; puede ser bajo cuando una categoría domina, aunque el acuerdo porcentual sea alto.

Precisión, recall y F1

$$Precisión = \frac{VP}{(VP + FP)} \cdot Recall = \frac{VP}{(VP + FN)}$$

$$F1 = 2 \times \frac{Precisión \times Recall}{Precisión + Recall}$$

- **Macro-F1:** calcula F1 por clase y luego promedia con igual peso. Es la métrica principal porque no permite que una clase frecuente oculte el mal resultado de las clases minoritarias.
- **Micro-F1:** reúne todas las decisiones antes de calcular F1; da más peso a las categorías frecuentes.
- **Exactitud:** proporción de ejemplos completamente correctos.
- **Balanced accuracy:** promedio del recall de las clases.

- **Hamming loss:** fracción de decisiones binarias de emoción incorrectas; cuanto menor, mejor.

Datos utilizados

Resumen

Elemento	Resultado
Mensajes del corpus	21.546
Periodo	16/12/2022–12/10/2026
Mensajes etiquetados	1.085
Textos únicos normalizados en la muestra	1.008
Filas duplicadas adicionales agrupadas	77
Documentos de la matriz documento-término	21.546
Términos de la matriz documento-término	10.421
Emociones modeladas	10
Particiones de validación cruzada	5

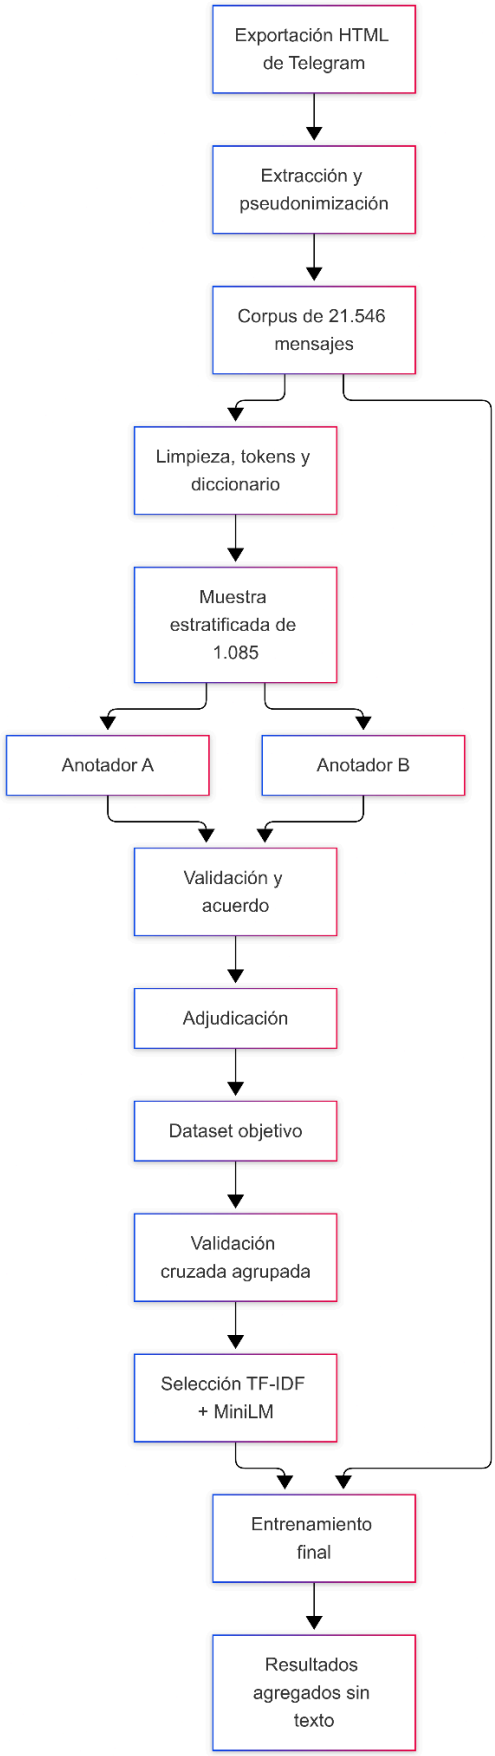
Distribución de la muestra por gestión

Gestión	Mensajes etiquetados
2022	185
2023	227
2024	224
2025	227
2026	222
Total	**1.085**

La muestra está aproximadamente balanceada por gestión, pero fue enriquecida por señales emocionales y por mensajes sin evidencia. Por ello sirve para entrenar y comparar clasificadores, pero no para estimar directamente la prevalencia real de emociones en las 21.546 publicaciones.

Metodología

El flujo toma como referencia las fases de CRISP-DM: comprensión del problema, comprensión de datos, preparación, modelado, evaluación y presentación.


Exportación HTML de Telegram
Extracción y pseudonimización
Corpus de 21.546 mensajes
Limpieza, tokens y diccionario
Muestra estratificada de 1.085
Anotador A
Anotador B
Validación y acuerdo
Adjudicación
Dataset objetivo
Validación cruzada agrupada
Selección TF-IDF + MiniLM
Entrenamiento final
Resultados agregados sin texto

Extracción y pseudonimización

Los archivos `messages.html`, `messages2.html`, etc. se localizaron y ordenaron automáticamente. Con `rvest` y `xml2` se extrajeron fecha, autor y texto. Se eliminaron eventos de servicio, filas sin fecha válida y contenido no textual. Luego se crearon variables de gestión, mes, hora y día de la semana.

Los nombres reales se sustituyeron por códigos secuenciales. El identificador `message_id` permite relacionar archivos sin usar el texto como clave.

Preprocesamiento

Se conservaron dos representaciones:

- texto original, únicamente en archivos privados, para trazabilidad y anotación;
- texto normalizado, para minería y comparación de duplicados.

Las operaciones principales fueron:

1. normalización Unicode;
2. conversión de URL a un marcador `<URL>` en Python;
3. conversión a minúsculas cuando corresponde;
4. compactación de espacios;
5. codificación previa de emojis y emoticonos para que no desaparezcan;
6. tokenización;
7. eliminación de stopwords, conservando negaciones importantes como “no”, “nunca” y “sin”;
8. stemming en español para los análisis descriptivos;
9. construcción de unigramas, bigramas y matriz documento-término.

Diccionario y cobertura

El diccionario original clasificó 2.034 de 21.546 mensajes. La ampliación contextual clasificó 5.299.

Versión	Clasificados	Sin coincidencia	Cobertura
Diccionario original	2.034	19.512	9,4%
Diccionario ampliado	5.299	16.247	24,6%

La cobertura creció 15,2 puntos porcentuales, pero **cobertura no significa exactitud**. Solo indica en cuántos mensajes hubo alguna coincidencia. La calidad se evaluó después contra las etiquetas humanas.

Muestreo

Se aplicó una semilla fija (`20261024`) para garantizar reproducibilidad. La muestra combinó:

- selección por gestión y emoción sugerida por las reglas;
- refuerzo de mensajes sin evidencia, para representar contenido informativo o difícil de clasificar;
- eliminación de duplicados por `message_id`.

Esta estrategia mejora la presencia de clases poco frecuentes. Su costo es que la distribución del dataset etiquetado deja de ser una estimación poblacional directa.

Anotación manual

Los dos anotadores trabajaron independientemente sobre 1.085 filas. No debían consultar `referencia_reglas_no_usar_al_etiquetar.csv`, porque ver una predicción previa puede producir sesgo de anclaje.

Por mensaje se registraron:

- presencia de sentimiento;
- polaridad;
- emoción principal y segunda emoción opcional;
- intensidad de 0 a 3;
- tema;
- ironía;
- confianza de la anotación;
- observaciones opcionales.

Validación y adjudicación

Los scripts comprobaron etiquetas permitidas, campos obligatorios, IDs duplicados y coherencia estructural. Las decisiones originales de A y B no se sobrescribieron. Los desacuerdos relevantes se copiaron a una plantilla separada y fueron resueltos mediante adjudicación.

La etiqueta objetivo se construyó así:

1. si A y B coincidían, se conservaba el acuerdo;
2. si no coincidían, se utilizaba la decisión adjudicada;
3. la fuente de cada objetivo quedaba registrada.

Resultado:

Fuente	Polaridad	Emociones
Acuerdo A/B	638	481
Adjudicación	447	604

Fuente	Polaridad	Emociones
Total	**1.085**	**1.085**

Modelado

Se compararon cinco alternativas bajo las mismas filas de prueba:

Modelo	Función
Baseline	Establece el mínimo que un modelo debe superar.
Diccionario	Reglas interpretables sin aprendizaje supervisado.
TF-IDF + logística	Aprende vocabulario y bigramas del dominio.
MiniLM + logística	Aprende sobre vectores semánticos preentrenados.
TF-IDF + MiniLM + logística	Combina vocabulario local y semántica.

La regresión logística utilizó `class_weight="balanced"`, `solver="lbfgs"`, `max_iter=3000` y semilla `20261026`. Para emociones se entrenó un clasificador binario por categoría mediante `OneVsRestClassifier`.

Validación cruzada sin fuga de información

Se normalizó cada texto y se calculó un hash SHA-256. Las 1.085 filas se redujeron a 1.008 grupos de texto único; había 77 repeticiones adicionales. Se aplicó `StratifiedGroupKFold` con cinco folds:

- la estratificación intenta conservar la distribución de polaridad;
- la agrupación mantiene juntas todas las copias del mismo texto;
- cada fila se evalúa exactamente una vez fuera de muestra;
- los resultados de las cinco partes forman las predicciones OOF (*out of fold*).

Sin la agrupación, un texto repetido podría aparecer en entrenamiento y prueba, inflando artificialmente las métricas.

Bitácora de limpieza y transformación

Esta sección incorpora la metodología solicitada en `bitacora.pdf` y la aplica al proyecto real. La bitácora funciona como un *audit trail*: registra qué se revisó, qué decisión se tomó, por qué se tomó y qué script permite reproducirla.

Correspondencia con la metodología solicitada

1. Auditoría y perfilado inicial

Antes de modificar los datos se inspeccionaron tipos, fechas, cardinalidades, ausencias y tamaños. El perfil final del corpus es:

Control	Resultado
Archivos HTML procesados	29
Mensajes válidos	21.546
IDs únicos	21.546
Participantes pseudonimizados	1.594
Texto faltante	0
Fecha faltante	0
Participante faltante	0
Longitud mínima / mediana / máxima	1 / 41 / 2.646 caracteres
Mensajes con URL	1.433
Emojis contabilizados	5.175

2. Normalización de estructura y formatos

Las fechas se convirtieron a ISO-8601 (`YYYY-MM-DD`), la hora a entero de 0 a 23 y las variables lógicas a valores consistentes. Para modelado se normalizó Unicode, se reemplazaron URL por `<URL>` y se compactaron espacios. Las etiquetas se pasaron a minúsculas, sin tildes y con guion bajo como separador.

No se sobrescribió el texto original: la versión original se conserva para auditoría y la normalizada se utiliza para minería. Esta separación permite revisar una transformación sin perder la fuente.

3. Gestión de duplicados

No se encontraron `message_id` repetidos en el corpus final. Sí existen mensajes textualmente idénticos, algo normal en un chat por respuestas breves, enlaces o publicaciones repetidas. En el corpus hay 17.457 textos normalizados únicos y 4.089 filas adicionales repetidas.

No se eliminaron todas esas filas porque cada una representa una publicación real en un momento determinado. Para evaluación predictiva se agruparon por hash: en la muestra manual hubo 1.008 grupos únicos y 77 repeticiones adicionales. Todas las copias de un texto permanecieron en el mismo fold.

4. Tratamiento de valores faltantes

No se imputó texto ni se inventaron etiquetas. Los eventos sin texto analizable se excluyeron durante la extracción. En la anotación, un objetivo vacío se trató como error y el pipeline se detuvo hasta que fuera completado o adjudicado. Después de la consolidación quedaron 1.085 polaridades y 1.085 conjuntos emocionales válidos.

Esta decisión es preferible a imputar con moda o media: una emoción faltante no es una medición numérica ausente, sino una decisión humana que debe revisarse.

5. Detección y tratamiento de valores atípicos

Se revisaron longitudes, cantidad de palabras, signos, enlaces y emojis. El mensaje más largo tiene 2.646 caracteres. No se aplicó eliminación automática mediante IQR o Z-score, porque un mensaje largo puede ser un anuncio académico válido y no un error. Los valores extremos se conservaron salvo que incumplieran una regla de validez, como fecha ilegible, ausencia total de texto o evento de servicio.

6. Consistencia y reglas de negocio

Se validaron categorías permitidas y relaciones lógicas. Algunos ejemplos son:

- `intensidad` solo puede ser 0, 1, 2 o 3;
- si no existe sentimiento, la emoción principal debe ser `sin_sentimiento`;
- polaridad y emociones objetivo no pueden quedar vacías;
- `message_id` debe ser único;
- las emociones deben pertenecer al libro de códigos;
- los desacuerdos A/B no pueden consolidarse sin adjudicación;
- al menos ocho emociones deben alcanzar el soporte mínimo de modelado;
- un texto duplicado no puede cruzar entrenamiento y prueba;
- las predicciones publicables no deben contener texto ni participante.

Registro de auditoría aplicado

Fecha	Responsable	Dataset o etapa	Problema o control	Acción realizada	Criterio y resultado	Filas afectadas o verificadas	Código
21/10/2026	Equipo	Exportación Telegram	Archivos fragmentados	Lectura y orden automático de `messages*.html`	Se procesaron 29 archivos en orden	29 archivos	`R/funciones.R`
21/10/2026	Equipo	Corpus	Eventos no analizables y fechas	Extracción de mensajes válidos y conversión de fechas	Corpus final de 21.546 mensajes entre 2022-12-16 y 2026-10-12	21.546 verificadas	`01_ejecutar_analisis.R`
21/10/2026	Equipo	Autor	Dato personal	Sustitución por códigos `P001`, `P002`, etc.	Minimización de identificación directa	21.546 mensajes; 1.594 códigos	`extraer_mensajes()`
21/10/2026	Equipo	Texto	Formatos heterogéneos	Minúsculas, Unicode, espacios, URL, emojis y normalización	Se conserva también el texto original	21.546 verificadas	`normalizar_texto()`
21/10/2026	Equipo	Corpus	Posibles duplicados de ID	Comprobación de unicidad	0 IDs duplicados	21.546 verificadas	`01_ejecutar_analisis.R`
21/10/2026	Equipo	Texto	Publicaciones repetidas	Conservación en corpus y agrupación en validación	17.457 textos únicos; 4.089 repeticiones adicionales	21.546 verificadas	`text_group()`
21/10/2026	Equipo	Diccionario	Baja cobertura inicial	Ampliación con variantes, expresiones,	Cobertura de 9,4% a 24,6%	3.265 mensajes adicionales cubiertos	`crear_diccionario()`

Fecha	Responsable	Dataset o etapa	Problema o control	Acción realizada	Criterio y resultado	Filas afectadas o verificadas	Código
				emojis y emoticonos			
21/10/2026	Equipo	Corpus	Necesidad de referencia humana	Muestreo estratificado por gestión y señal, más refuerzo sin evidencia	Semilla fija `20261024`	1.085 seleccionadas	`02_generar_dataset_manual.R`
26/10/2026	Equipo	Etiquetado B	Tres valores mecánicamente inválidos en una etapa intermedia	Normalización documentada sin inventar decisiones semánticas	Correcciones trazables	3 celdas	`06_corregir_etiquetado_b.R`
26/10/2026	Anotadores A/B	Etiquetado	Campos incompletos o inválidos	Validación de categorías, IDs y obligatoriedad	A y B: 1.085 filas válidas, 0 errores finales	2.170 anotaciones	`03_validar_dataset_manual.R`
26/10/2026	Equipo	Consenso	Desacuerdo humano	Adjudicación separada sin sobrescribir A ni B	447 polaridades y 604 conjuntos emocionales adjudicados	1.051 decisiones objetivo	`07_consolidar_adjudicaciones.R`
26/10/2026	Equipo	Modelado	Riesgo de fuga por repetición	Cinco folds estratificados y agrupados por SHA-256	1.008 grupos; 77 repeticiones controladas	1.085 evaluadas OOF	`09_validacion_cruzada.py`
26/10/2026	Equipo	Selección	Comparación desigual de clases	Selección por macro-F1 entre modelos aprendidos	Ganó TF-IDF + MiniLM	5 modelos comparados	`09_validacion_cruzada.py`

Fecha	Responsable	Dataset o etapa	Problema o control	Acción realizada	Criterio y resultado	Filas afectadas o verificadas	Código
26/10/2026	Equipo	Corpus completo	Salida con posible información privada	Exclusión de texto y participante	21.546 predicciones protegidas	21.546 clasificadas	`10_clasificar_corpus.py`

Trazabilidad automática de ejecuciones

`resultados/datos/bitacora_ejecuciones.csv` conserva fecha y hora, número de HTML, mensajes analizados, periodo y huellas MD5 de las entradas. Las huellas permiten comprobar si se volvió a ejecutar el análisis con exactamente los mismos archivos.

La bitácora humana se mantiene en `BITACORA.md`; la bitácora automática registra ejecuciones del pipeline, y esta tabla reúne ambas fuentes en el formato solicitado por la guía de limpieza.

Implementación: código esencial

Esta sección resume los fragmentos que mejor justifican las decisiones técnicas. El código completo se conserva en `R/` y `scripts/`.

Normalización de etiquetas

```
normalizar_etiqueta <- function(x) {
  x |>
    dplyr::coalesce("") |>
    stringi::stri_trans_general("Latin-ASCII") |>
    stringr::str_to_lower() |>
    stringr::str_squish() |>
    stringr::str_replace_all("[ /-]+", "_")
}
```

Esto evita que valores equivalentes como `Alegría`, `alegria` o `ALEGRIA` se interpreten como categorías diferentes.

Creación reproducible de la muestra

```
set.seed(20261024)

estratificada <- universo |>
  dplyr::group_by(gestion, estrato) |>
  dplyr::group_modify(
    ~ dplyr::slice_sample(.x, n = min(n_por_estrato, nrow(.x)))
  ) |>
  dplyr::ungroup()
```

La semilla permite obtener la misma selección al repetir el procedimiento sobre el mismo corpus.

Construcción del objetivo adjudicado

```r
final <- datos |>
  dplyr::left_join(adjudicadas, by = "message_id") |>
  dplyr::mutate(
    polaridad_objetivo = dplyr::case_when(
      acuerdo_polaridad ~ polaridad_consenso,
      doble_anotacion ~ polaridad_adjudicada,
      TRUE ~ polaridad_manual
    ),
    fuente_polaridad = dplyr::case_when(
      acuerdo_polaridad ~ "acuerdo_ab",
      doble_anotacion ~ "adjudicado",
      TRUE ~ "solo_a"
    )
  )
```

La procedencia de la etiqueta queda explícita y puede auditarse.

Agrupación de textos duplicados

```python
def text_group(value: object) -> str:
    normalized = normalize_text(value).lower()
    return hashlib.sha256(normalized.encode("utf-8")).hexdigest()

splitter = StratifiedGroupKFold(
    n_splits=5,
    shuffle=True,
    random_state=20261026,
)

splits = splitter.split(
    data,
    data["polaridad_objetivo"],
    groups=data["text_group"],
)
```

El hash no se utiliza como característica del modelo; únicamente identifica textos iguales para separarlos correctamente.

TF-IDF y representación híbrida

```python
vectorizer = TfidfVectorizer(
    ngram_range=(1, 2),
    min_df=2,
    max_features=30000,
    sublinear_tf=True,
)
```

```
tfidf_train = vectorizer.fit_transform(text_train)
tfidf_test = vectorizer.transform(text_test)

hybrid_train = sparse.hstack(
    [tfidf_train, sparse.csr_matrix(embedding_train)],
    format="csr",
)
hybrid_test = sparse.hstack(
    [tfidf_test, sparse.csr_matrix(embedding_test)],
    format="csr",
)
```

El vectorizador se ajusta solo con el fold de entrenamiento. Ajustarlo antes de dividir los datos permitiría que el vocabulario de prueba influyera en el proceso.

Clasificador balanceado

```
def logistic():
    return LogisticRegression(
        max_iter=3000,
        class_weight="balanced",
        solver="lbfgs",
        random_state=20261026,
    )

emotion_classifier = OneVsRestClassifier(logistic(), n_jobs=-1)
emotion_classifier.fit(x_train, y_emotions_train)
```

`class_weight="balanced"` aumenta el peso relativo de las clases escasas. No crea datos nuevos ni garantiza que las clases muy pequeñas sean aprendidas.

Predicción multietiqueta

```
emotion_probability = emotion_classifier.predict_proba(x_corpus)
emotion_prediction = (emotion_probability >= 0.5).astype(int)

emotion_labels = [
    ";".join(labels) if labels else "sin_sentimiento"
    for labels in mlb.inverse_transform(emotion_prediction)
]
```

Cada emoción obtiene una probabilidad independiente. El umbral global es 0,5. Si ninguna emoción lo supera, la salida se registra como `sin_sentimiento`.

Protección de la salida final

```
predictions = pd.DataFrame({
    "message_id": corpus["message_id"],
    "gestion": corpus["gestion"],
    "fecha": corpus["fecha"],
    "hora": corpus["hora"],
    "polaridad_predicha": polarity_prediction,
```

```
    "confianza_polaridad": polarity_probability.max(axis=1),
    "emociones_predichas": emotion_labels,
    "confianza_emocion_max": emotion_probability.max(axis=1),
})
```

No se exportan `texto` ni `participante` en `predicciones_corpus.csv`.

Guía de los archivos CSV

Regla de lectura

Cada fila representa un mensaje, una clase o una combinación de agrupación según el archivo. El separador entre columnas es coma. Cuando una celda contiene varias emociones, se usa punto y coma, por ejemplo `preocupacion;tristeza`.

Los siguientes ejemplos son **sintéticos**: explican la estructura sin copiar mensajes reales del grupo. Para facilitar la lectura se muestran únicamente las columnas relevantes; los archivos reales pueden contener columnas descriptivas adicionales.

corpus_anonimizado.csv

Contiene el corpus completo pseudonimizado. Debe mantenerse privado porque conserva texto y código de participante.

```
message_id,gestion,fecha,hora,participante,texto
message_demo_001,2026,2026-01-10,9,P001,"¿Alguien sabe el horario de
inscripción?"
message_demo_002,2026,2026-01-10,10,P002,"Muchas gracias por la ayuda"
```

- `message_id`: identificador estable;
- `gestion`, `fecha`, `hora`: variables temporales;
- `participante`: seudónimo;
- `texto`: contenido original privado.

etiquetado_anotador_a.csv y etiquetado_anotador_b.csv

Son las hojas independientes de anotación. Las columnas descriptivas no deben alterarse; los anotadores completan las variables manuales.

```
message_id,texto,tiene_sentimiento,polaridad_manual,sentimiento_1,sentimiento
_2,intensidad,tema,ironia,confianza_anotacion,responsable
message_demo_002,"Muchas gracias por la
ayuda",si,positiva,gratitud,alegria,2,conversacion_social,no,alta,ANOTADOR_A
```

Interpretación: el anotador considera que existe sentimiento positivo, selecciona gratitud como emoción principal, alegría como secundaria y asigna intensidad media.

referencia_reglas_no_usar_al_etiquetar.csv

Guarda la salida del diccionario para compararla posteriormente con las decisiones humanas. No debe mostrarse durante la anotación.

```
message_id,polaridad_regla,motivo_no_clasificado,emociones_regla,evidencias_regla,tipos_regla
message_demo_002,positiva,clasificado,gratitud,"muchas gracias",termino_exacto
```

Este archivo permite responder **por qué** se activó una regla.

dataset_consenso_umsa.csv

Reúne A y B sin destruir sus decisiones. Sus campos indican si hubo doble anotación, si coincidieron y cuál es el estado del consenso.

```
message_id,polaridad_manual,polaridad_b,acuerdo_polaridad,sentimientos_a,sentimientos_b,acuerdo_sentimientos,estado_consenso
message_demo_002,positiva,positiva,TRUE,gratitud;alegria,gratitud,FALSE,desacuerdo_ab
```

En el ejemplo hay acuerdo en polaridad, pero desacuerdo en el conjunto exacto de emociones. Por ello solo la parte emocional necesita adjudicación.

desacuerdos_modelado.csv

Es la plantilla donde se resuelven diferencias que afectan al modelo.

```
message_id,polaridad_a,polaridad_b,sentimientos_a,sentimientos_b,polaridad_adjudicada,sentimiento_1_adjudicado,sentimiento_2_adjudicado,intensidad_adjudicada,tema_adjudicado,ironia_adjudicada,observaciones_adjudicacion
message_demo_002,positiva,positiva,alegria;gratitud,gratitud,positiva,gratitud,alegria,2,conversacion_social,no,"Revisión final: Integrante"
```

La adjudicación no significa escoger automáticamente A o B: requiere revisar el mensaje y aplicar el libro de códigos.

dataset_modelado_umsa.csv

Es la referencia final para entrenamiento y evaluación. Conserva los campos anteriores y añade objetivos y procedencia.

```
message_id,polaridad_objetivo,sentimientos_objetivo,fuente_polaridad,fuente_sentimientos,apto_test_alta_confianza
message_demo_002,positiva,alegria;gratitud,acuerdo_ab,adjudicado,TRUE
```

Las columnas clave para Python son:

- `texto`: entrada del modelo, únicamente en el entorno privado;
- `polaridad_objetivo`: clase multiclase;

- `sentimientos_objetivo`: conjunto multietiqueta;
- `polaridad_regla` y `emociones_regla`: baseline del diccionario.

control_calidad.csv

Contiene una sola fila con totales, errores y métricas de acuerdo.

```
filas_totales,completas_anotador_a,errores_a,completas_anotador_b,errores_b,kappa_polaridad,kappa_sentimiento
1085,1085,0,1085,0,0.418452,0.432436
```

comparacion_modelos.csv

Cada fila es una combinación de tarea y modelo evaluada sobre predicciones OOF.

```
task,model,n_test,accuracy,balanced_accuracy,macro_f1,micro_f1,hamming_loss
polaridad,hibrido_tfidf_minilm,1085,0.529954,0.401263,0.393032,0.529954,
emociones_multietiqueta,hibrido_tfidf_minilm,1085,0.444240,,0.375453,0.382315
,0.087558
```

Las celdas vacías son métricas no aplicables, no errores. Por ejemplo, Hamming loss se usa en la tarea multietiqueta, no en la clasificación única de polaridad.

metricas_por_fold.csv, resumen_folds.csv y metricas_por_clase.csv

- `metricas_por_fold.csv`: desempeño de cada modelo en cada una de las cinco partes;
- `resumen_folds.csv`: promedio y desviación estándar entre folds;
- `metricas_por_clase.csv`: precisión, recall, F1 y soporte de cada clase.

Estos archivos permiten demostrar que no se reportó únicamente el mejor número.

predicciones_corpus.csv

Contiene las salidas finales sin texto ni participante.

```
message_id,gestion,fecha,hora,es_muestra_manual,polaridad_predicha,confianza_polaridad,emociones_predichas,confianza_emocion_max
message_demo_002,2026,2026-01-10,10,TRUE,positiva,0.81,alegria;gratitud,0.76
```

`confianza_polaridad` es la mayor probabilidad entre las seis polaridades.
`confianza_emocion_max` es la probabilidad emocional más alta, aunque puede haber varias emociones activadas.

Resultados

Calidad de la anotación

Los dos archivos quedaron completos y sin errores estructurales.

Indicador	Resultado
Filas totales	1.085
Filas completas A	1.085
Filas completas B	1.085
Errores A/B	0 / 0
Duplicados A/B	0 / 0
Kappa de polaridad	0,418
Kappa de emoción principal	0,432
Jaccard de conjuntos emocionales	0,523
Acuerdo exacto de emociones	0,443

Detalle por variable:

Variable	Acuerdo observado	Kappa
Presencia de sentimiento	70,7%	0,446
Polaridad	58,8%	0,418
Emoción principal	57,4%	0,432
Intensidad	55,6%	0,295
Tema	41,6%	0,324
Ironía	94,7%	0,220
Confianza del anotador	45,7%	-0,016

El acuerdo de polaridad y emoción es moderado. No se debe ocultar este resultado: demuestra que el problema tiene ambigüedad real. El caso de ironía ilustra por qué se reportan acuerdo y kappa juntos: casi todos los mensajes fueron marcados como no irónicos, por lo que existe alto acuerdo bruto pero menor información más allá del azar. La confianza es una autoevaluación subjetiva y no se utilizó como objetivo.

Distribución del dataset adjudicado

Polaridad	Mensajes	Porcentaje
Sin sentimiento	458	42,2%
Negativa	251	23,1%
Positiva	155	14,3%
Neutra	142	13,1%
Ambigua	53	4,9%
Mixta	26	2,4%
Total	**1.085**	**100%**

Las emociones seleccionadas para modelado presentan el siguiente soporte:

Emoción	Casos	Emoción	Casos
Curiosidad	143	Preocupación	108
Decepción	60	Confusión	52
Esperanza	51	Gratitud	43
Tristeza	29	Alegría	28
Admiración	24	Enojo	24

En la referencia completa también existen emociones con menos de veinte casos, pero no se incluyeron en el benchmark final porque sus métricas serían muy inestables.

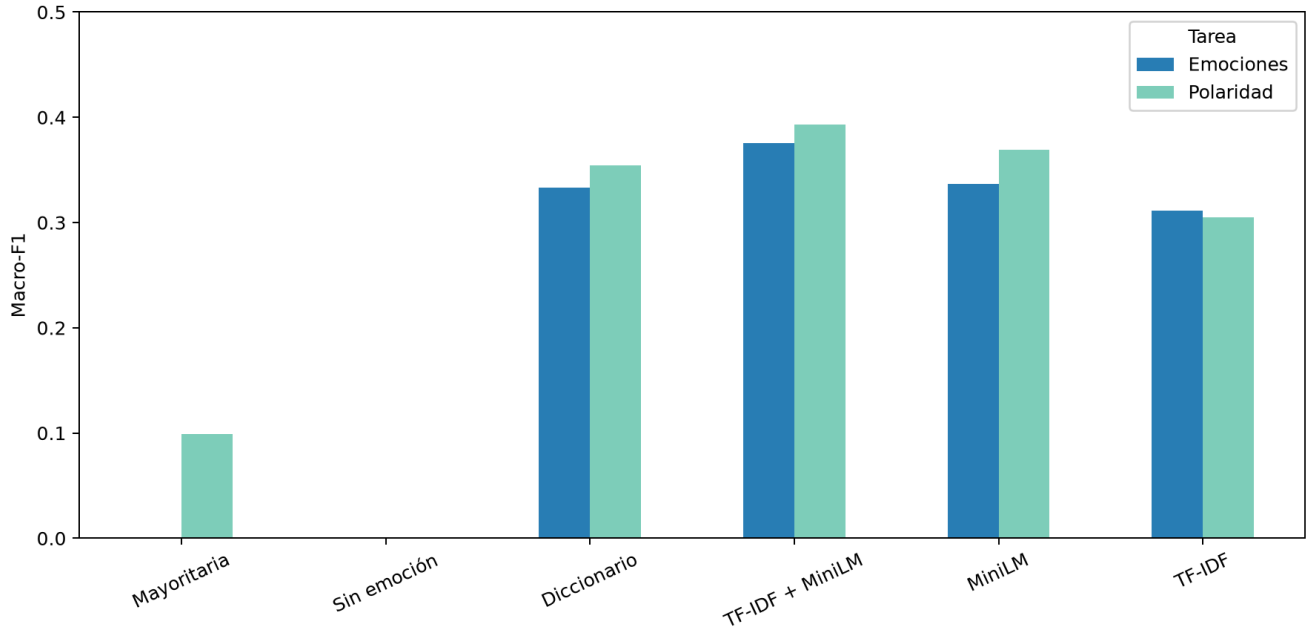
Comparación de modelos

Polaridad

Modelo	Exactitud	Balanced accuracy	Macro-F1
Baseline mayoritario	0,422	0,167	0,099
Diccionario	**0,540**	0,376	0,354
TF-IDF	0,399	0,319	0,305
MiniLM	0,471	0,382	0,369
TF-IDF + MiniLM	0,530	**0,401**	**0,393**

Emociones multietiqueta

Modelo	Exactitud de conjunto	Macro-F1	Micro-F1	Hamming loss
Baseline sin emoción	**0,492**	0,000	0,000	**0,052**
Diccionario	0,478	0,333	0,323	0,071
TF-IDF	0,386	0,312	0,325	0,091
MiniLM	0,291	0,336	0,340	0,133
TF-IDF + MiniLM	0,444	**0,375**	**0,382**	0,088



Comparación de macro-F1 de los modelos

Interpretación

El modelo híbrido se seleccionó mediante macro-F1, no mediante exactitud. En polaridad, el diccionario obtiene una exactitud ligeramente mayor, pero el híbrido equilibra mejor el reconocimiento de las seis clases. En emociones, el baseline parece tener buena exactitud y bajo Hamming loss porque predice siempre "ninguna emoción". Su macro-F1 es cero: nunca encuentra una emoción real. Este resultado demuestra que una única métrica puede ser engañosa en datos desbalanceados.

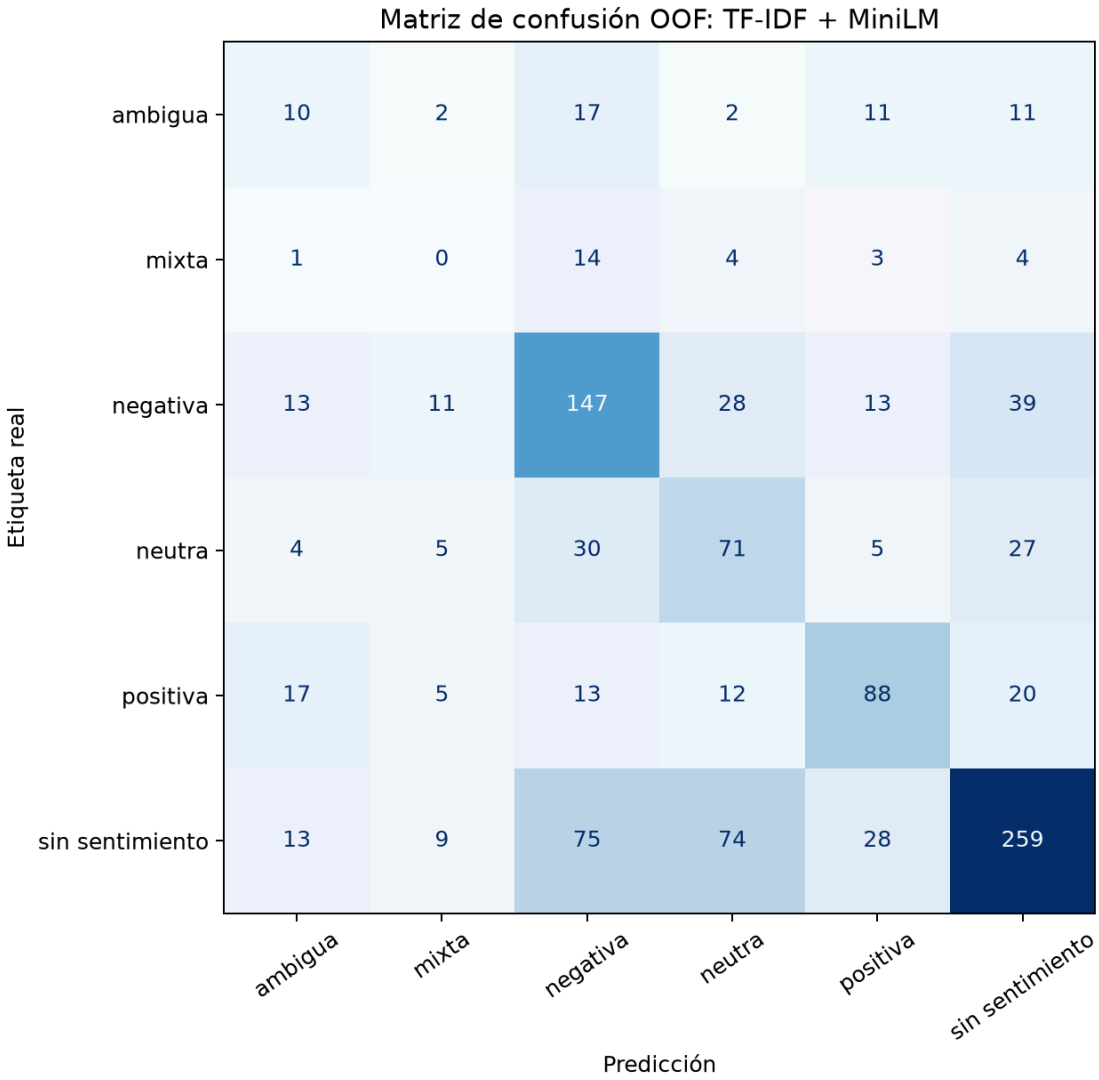
MiniLM supera a TF-IDF en polaridad, lo cual aporta evidencia de que la representación semántica ayuda. La combinación vuelve a mejorar porque conserva simultáneamente semántica general y vocabulario local.

El promedio entre folds del híbrido fue:

Tarea	Macro-F1 promedio	Desviación estándar
Polaridad	0,391	0,026
Emociones	0,365	0,059

La variación mayor en emociones se relaciona con su menor soporte y con la dificultad de mantener exactamente la misma distribución multietiqueta en cada fold.

Matriz de confusión de polaridad



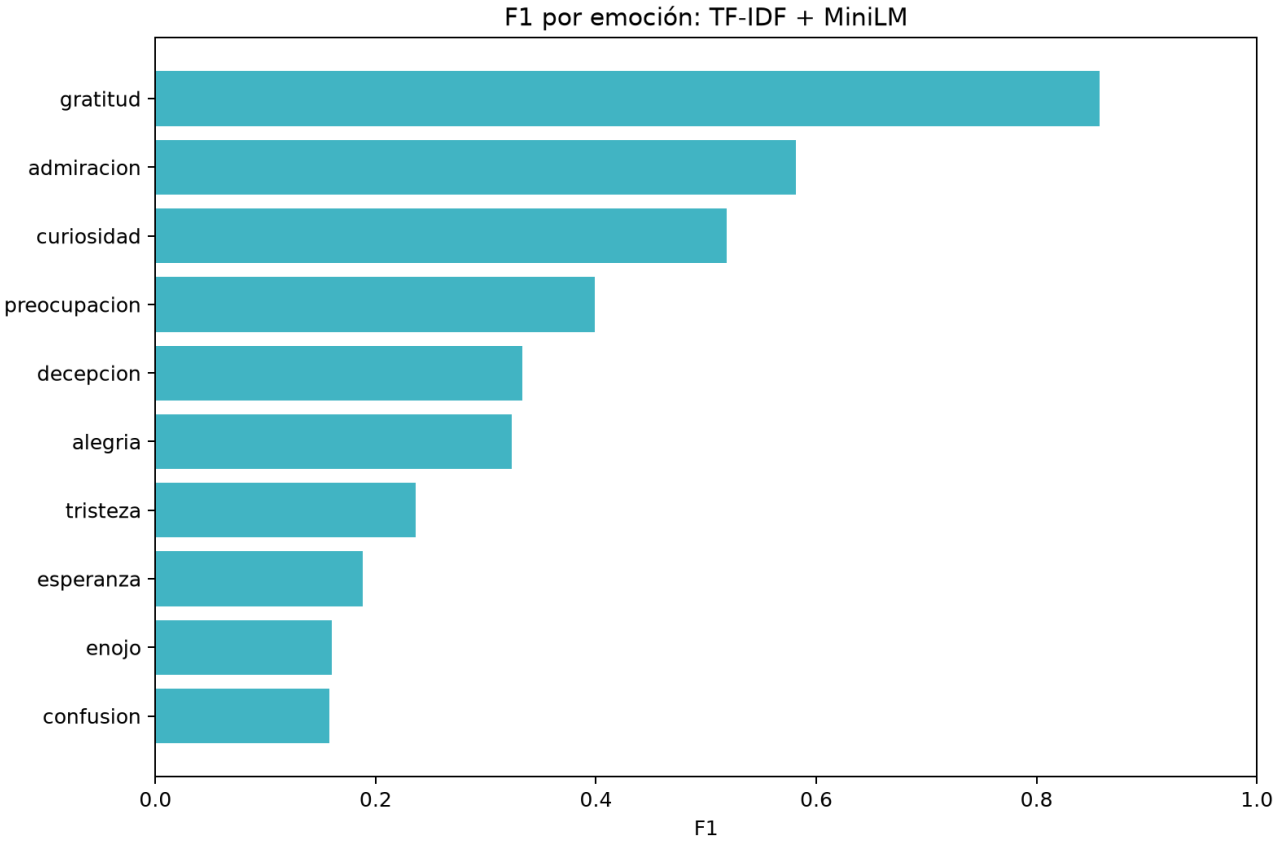
Matriz de confusión OOF del modelo híbrido

Métricas por clase del modelo híbrido:

Polaridad	Soporte	Precisión	Recall	F1
Ambigua	53	0,172	0,189	0,180
Mixta	26	0,000	0,000	0,000
Negativa	251	0,497	0,586	0,537
Neutra	142	0,372	0,500	0,426
Positiva	155	0,595	0,568	0,581
Sin sentimiento	458	0,719	0,566	0,633

La clase mixta no fue reconocida fuera de muestra. Solo tenía 26 ejemplos y requiere detectar simultáneamente señales de signo contrario. Ambigua también es difícil por definición. Las mejores clases fueron sin sentimiento, positiva y negativa.

Desempeño por emoción



F1 por emoción del modelo híbrido

Emoción	Soporte	Precisión	Recall	F1
Gratitud	43	0,878	0,837	**0,857**
Admiración	24	0,516	0,667	0,582
Curiosidad	143	0,434	0,643	0,518
Preocupación	108	0,314	0,546	0,399
Decepción	60	0,246	0,517	0,333
Alegría	28	0,225	0,571	0,323
Tristeza	29	0,148	0,586	0,236
Esperanza	51	0,167	0,216	0,188
Enojo	24	0,154	0,167	0,160
Confusión	52	0,120	0,231	0,158

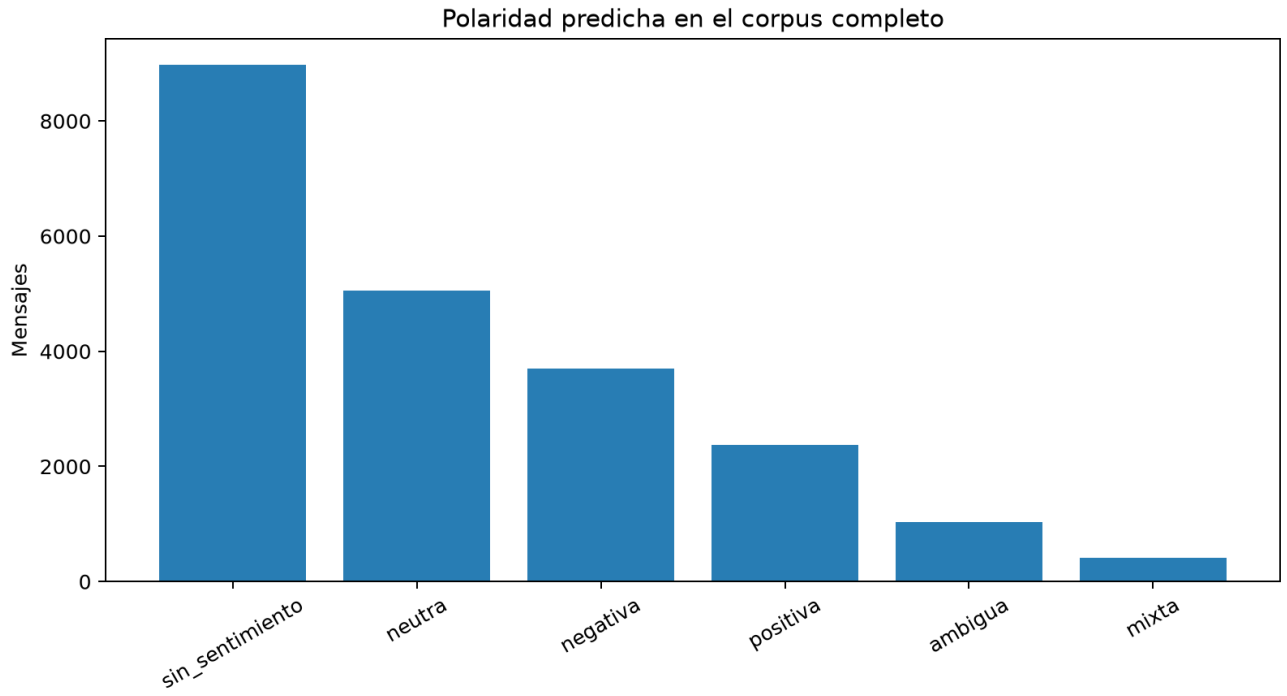
Gratitud posee expresiones relativamente distintivas. Confusión, enojo, esperanza y tristeza presentan menor precisión o recall porque comparten vocabulario con consultas, problemas académicos y otras emociones. El soporte por sí solo no explica todo: admiración tiene pocos casos, pero señales lingüísticas más reconocibles.

Clasificación del corpus completo

Una vez seleccionado el híbrido, se volvió a entrenar con las 1.085 filas y se clasificaron 21.546 mensajes. Estas cifras no son etiquetas humanas; son estimaciones del modelo final.

Polaridad predicha

Polaridad	Mensajes	Porcentaje
Sin sentimiento	8.974	41,65%
Neutra	5.055	23,46%
Negativa	3.694	17,14%
Positiva	2.378	11,04%
Ambigua	1.030	4,78%
Mixta	415	1,93%
Total	**21.546**	**100%**



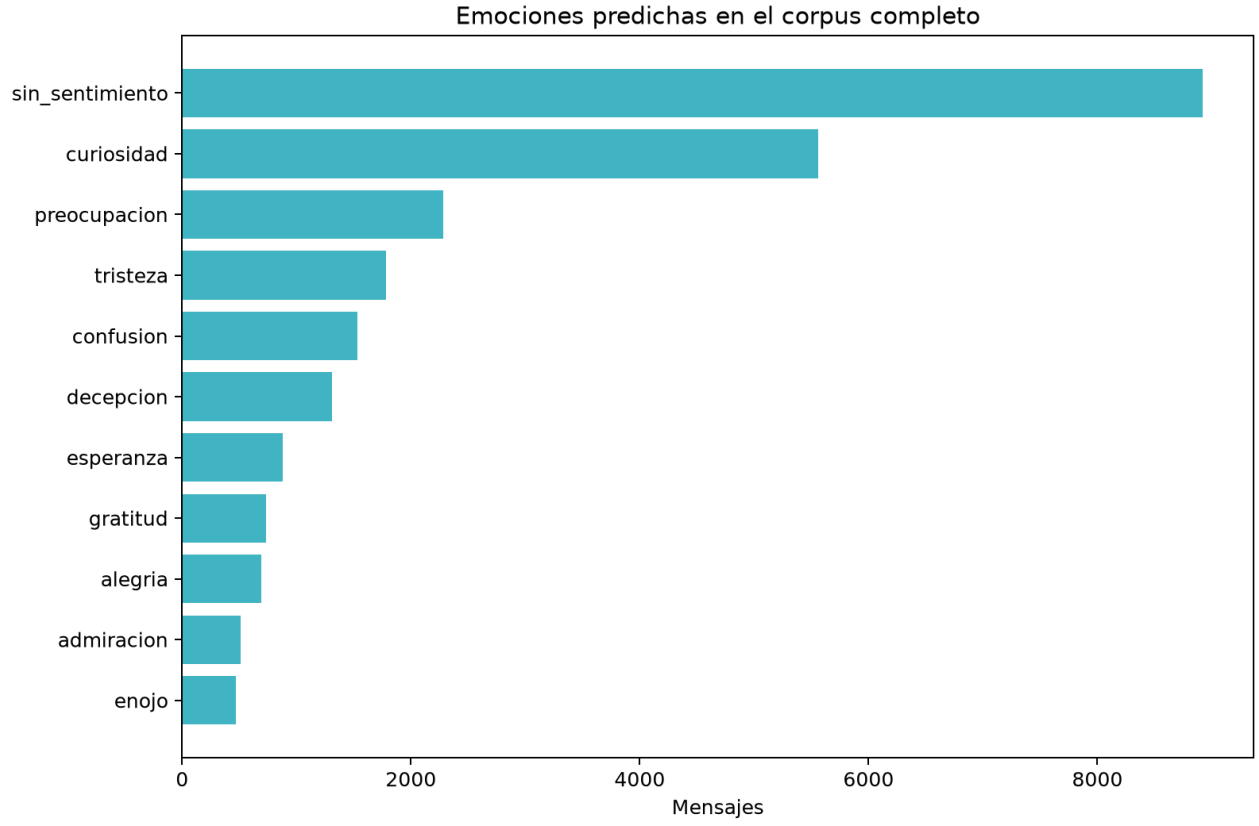
Polaridad predicha en el corpus completo

La mayoría de los mensajes es informativa o neutral, lo cual es coherente con un grupo académico orientado a consultas y coordinación. No debe afirmarse que "el grupo es

negativo": la predicción negativa corresponde al 17,14% y además está sujeta al error observado en validación.

Emociones predichas

Emoción	Mensajes	Porcentaje de mensajes
Sin sentimiento	8.919	41,40%
Curiosidad	5.558	25,80%
Preocupación	2.280	10,58%
Tristeza	1.783	8,28%
Confusión	1.531	7,11%
Decepción	1.309	6,08%
Esperanza	879	4,08%
Gratitud	731	3,39%
Alegría	694	3,22%
Admiración	513	2,38%
Enojo	467	2,17%



Emociones predichas en el corpus completo

Los porcentajes emocionales pueden sumar más de 100% porque un mensaje puede tener más de una emoción. Curiosidad es la emoción más frecuente, algo razonable en un chat donde predominan preguntas. Sin embargo, esta interpretación debe matizarse: el modelo puede confundir construcciones interrogativas con curiosidad emocional.

Variación de polaridad por gestión

Gestión	Sin sentimiento	Neutra	Negativa	Positiva
2022	49,8%	15,6%	17,8%	12,0%
2023	43,8%	20,6%	17,8%	11,1%
2024	40,8%	25,3%	16,6%	10,7%
2025	39,5%	23,9%	18,3%	11,2%
2026	42,3%	25,3%	15,1%	11,0%

La tabla es descriptiva. No se aplicaron pruebas de significancia causal y la actividad mensual no es uniforme; por ello no se debe atribuir un cambio a una materia, docente o evento sin análisis adicional.

Confianza de las predicciones

Variable	Mínimo	Mediana	Media	Máximo
Máxima probabilidad de polaridad	0,183	0,423	0,465	0,976
Máxima probabilidad emocional	0,066	0,558	0,554	0,998

Una mediana de 0,423 en polaridad indica incertidumbre considerable. La palabra “confianza” describe la salida probabilística del clasificador, pero no significa que las probabilidades estén perfectamente calibradas. Los casos de baja confianza son candidatos naturales para revisión humana.

Discusión

El trabajo muestra que ninguna representación resuelve por sí sola el lenguaje del chat. El diccionario es explicable y competitivo, pero su cobertura es limitada y no siempre interpreta el contexto. TF-IDF captura vocabulario local, mientras que MiniLM reconoce semejanzas semánticas. El mejor macro-F1 del híbrido respalda que estas fuentes son complementarias.

Las métricas absolutas son moderadas. Esto no invalida el proyecto; muestra la dificultad real y evita presentar un resultado inflado. Tres factores son centrales:

1. acuerdo humano moderado, que establece un límite práctico de consistencia;

2. clases minoritarias, especialmente mixta, ambigua y algunas emociones;
3. mensajes aislados sin contexto conversacional.

El aporte metodológico más importante es la existencia de una referencia propia, doble anotación, adjudicación y evaluación OOF agrupada. Sin estas etapas sería posible mostrar porcentajes atractivos, pero no saber si el sistema reconoce correctamente las emociones.

Limitaciones y amenazas a la validez

1. **Muestreo enriquecido.** La muestra no es aleatoria simple y no representa directamente la prevalencia del corpus.
2. **Pocos ejemplos por clase.** Algunas emociones no alcanzaron veinte casos; mixta solo tiene 26.
3. **Contexto incompleto.** Los mensajes se clasifican individualmente y no se incorporan respuestas anteriores.
4. **Contenido no textual.** No se analizan audios, imágenes, videos o stickers sin transcripción.
5. **Ironía y negación.** Continúan siendo fenómenos difíciles.
6. **Dominio local.** MiniLM es multilingüe y general, no fue preentrenado específicamente con lenguaje universitario boliviano.
7. **Umbral único.** Todas las emociones utilizan 0,5; umbrales por clase podrían mejorar el equilibrio entre precisión y recall.
8. **Probabilidades no calibradas.** La probabilidad máxima no es garantía de corrección.
9. **Deriva temporal.** El vocabulario y las prácticas del grupo pueden cambiar en nuevas gestiones.
10. **Generalización externa.** Los resultados describen este grupo y no toda la población estudiantil de Informática.

Conclusiones

1. Se construyó un pipeline reproducible desde la exportación de Telegram hasta resultados agregados y protegidos.
2. Se obtuvo un corpus de 21.546 mensajes y un dataset propio de 1.085 ejemplos con doble anotación y adjudicación completa.
3. El acuerdo moderado confirma que la clasificación de emociones posee ambigüedad real y que era necesaria una etapa de consenso.
4. La ampliación del diccionario elevó la cobertura de 9,4% a 24,6%, pero la cobertura no sustituyó la evaluación contra etiquetas humanas.
5. MiniLM superó a TF-IDF en polaridad, lo que evidencia utilidad de la información semántica.
6. TF-IDF + MiniLM obtuvo el mejor macro-F1: 0,393 en polaridad y 0,375 en diez emociones.

7. La validación agrupada evitó la fuga producida por 77 filas repetidas más allá de la primera aparición.
8. Se clasificó el corpus completo sin incluir texto ni participantes en la salida final.
9. Los resultados son útiles para estudiar tendencias generales, pero no para diagnosticar o evaluar individuos.

Recomendaciones

1. Aumentar el número de ejemplos de polaridad mixta, ambigua y emociones con bajo soporte.
2. Realizar una segunda ronda de adjudicación con reglas más detalladas para las categorías que más se confunden.
3. Evaluar umbrales específicos por emoción mediante validación interna.
4. Incorporar uno o dos mensajes de contexto anterior, con controles de privacidad.
5. Calibrar las probabilidades y definir una zona de abstención para baja confianza.
6. Comparar modelos en español o ajustar un transformer solo cuando exista un dataset suficientemente grande.
7. Auditar una muestra aleatoria del corpus completo, independiente del muestreo original, para estimar calidad en uso real.
8. Repetir la evaluación al incorporar nuevas gestiones y vigilar deriva de datos.

Reproducibilidad

Desde la raíz del proyecto:

```
Rscript scripts/00_instalar_paquetes.R
Rscript scripts/01_ejecutar_analisis.R
Rscript scripts/02_generar_dataset_manual.R

# Después de completar A y B:
Rscript scripts/06_corregir_etiquetado_b.R
Rscript scripts/03_validar_dataset_manual.R

# Después de adjudicar los desacuerdos:
Rscript scripts/07_consolidar_adjudicaciones.R
Rscript scripts/04_mineria_descriptiva.R
Rscript scripts/05_preprocesamiento_librerias.R
```

Entorno de embeddings:

```
python3 -m venv .venv-embeddings
.venv-embeddings/bin/pip install -r requirements-embeddings.txt
```

Validación y clasificación:

```
HF_HUB_OFFLINE=1 TRANSFORMERS_OFFLINE=1 \
  .venv-embeddings/bin/python scripts/09_validacion_cruzada.py

HF_HUB_OFFLINE=1 TRANSFORMERS_OFFLINE=1 \
  .venv-embeddings/bin/python scripts/10_clasificar_corpus.py --batch-size
256
```

Conversión opcional del Markdown a Word mediante Pandoc:

```
pandoc informe/Informe_defensa_Data_Mining.md \
  --from gfm+tex_math_dollars \
  --toc --number-sections \
  --resource-path=informe:. \
  -o informe/Informe_defensa_Data_Mining.docx
```

Al convertirlo, se debe revisar la carátula, actualizar el índice, ajustar el tamaño de las figuras y verificar el estilo solicitado por la docente.

Estructura del proyecto

```
.
|-- R/
|   |-- funciones.R
|   |-- dataset_manual.R
|   `-- preprocesamiento_texto.R
|-- scripts/
|   |-- 01_ejecutar_analisis.R
|   |-- 02_generar_dataset_manual.R
|   |-- 03_validar_dataset_manual.R
|   |-- 04_mineria_descriptiva.R
|   |-- 05_preprocesamiento_librerias.R
|   |-- 06_corregir_etiquetado_b.R
|   |-- 07_consolidar_adjudicaciones.R
|   |-- 08_modelo_embeddings.py
|   |-- 09_validacion_cruzada.py
|   `-- 10_clasificar_corpus.py
|-- datos/dataset_manual/
|-- resultados/validacion_cruzada/
|-- resultados/modelo_final/
|-- informe/
|-- configuracion.R
|-- requirements-embeddings.txt
`-- sentimientos_documento.pdf
```

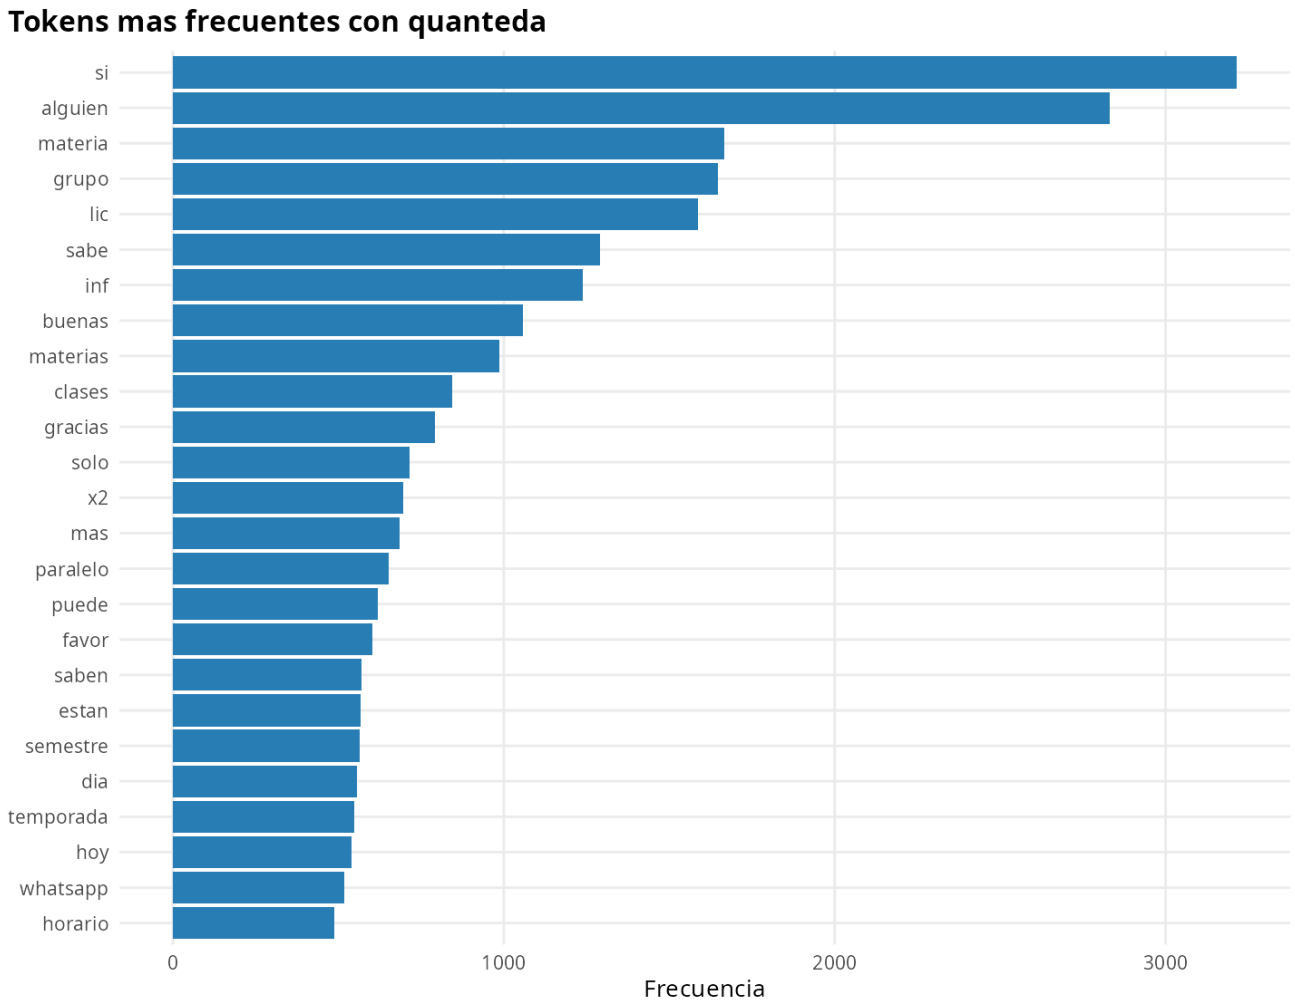
Archivos principales producidos

Archivo	Propósito	Privacidad
`corpus_anonimizado.csv`	Corpus completo con seudónimos	Privado
`etiquetado_anotador_a.csv`	Decisiones originales de A	Privado
`etiquetado_anotador_b.csv`	Decisiones originales de B	Privado
`dataset_consenso_umsa.csv`	Comparación A/B	Privado
`desacuerdos_modelado.csv`	Adjudicación	Privado
`dataset_modelado_umsa.csv`	Referencia final	Privado
`comparacion_modelos.csv`	Métricas OOF agregadas	Presentable
`resumen_folds.csv`	Media y dispersión entre folds	Presentable
`metricas_por_clase.csv`	Rendimiento por categoría	Presentable
`predicciones_oof_privadas.csv`	Predicción por fila etiquetada	Privado
`predicciones_corpus.csv`	Predicciones sin texto ni participante	Uso interno/presentable con cautela
`resumen_polaridad.csv`	Distribución agregada final	Presentable
`resumen_emociones.csv`	Distribución emocional agregada	Presentable

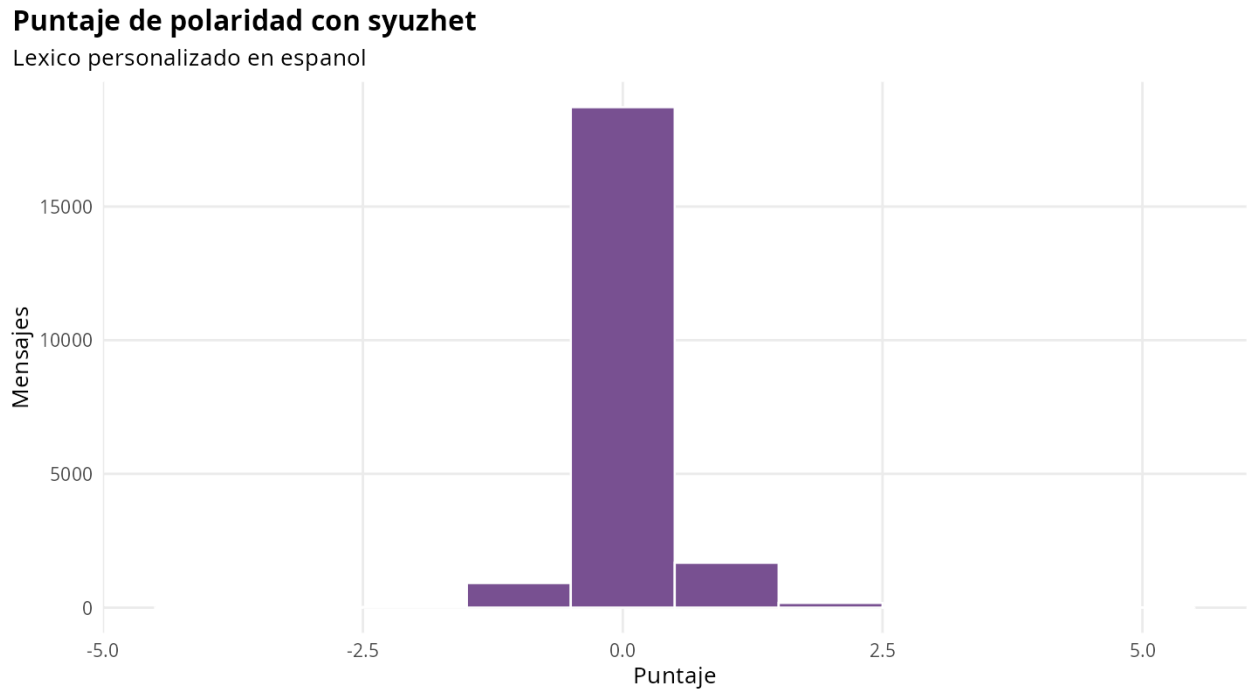
Evidencias visuales y capturas

Las siguientes capturas son productos reproducibles de los scripts. Se incluyen como evidencia del preprocesamiento, diagnóstico del diccionario, preparación del dataset y evaluación del modelo. No se muestran pantallas del chat ni mensajes reales para proteger la privacidad.

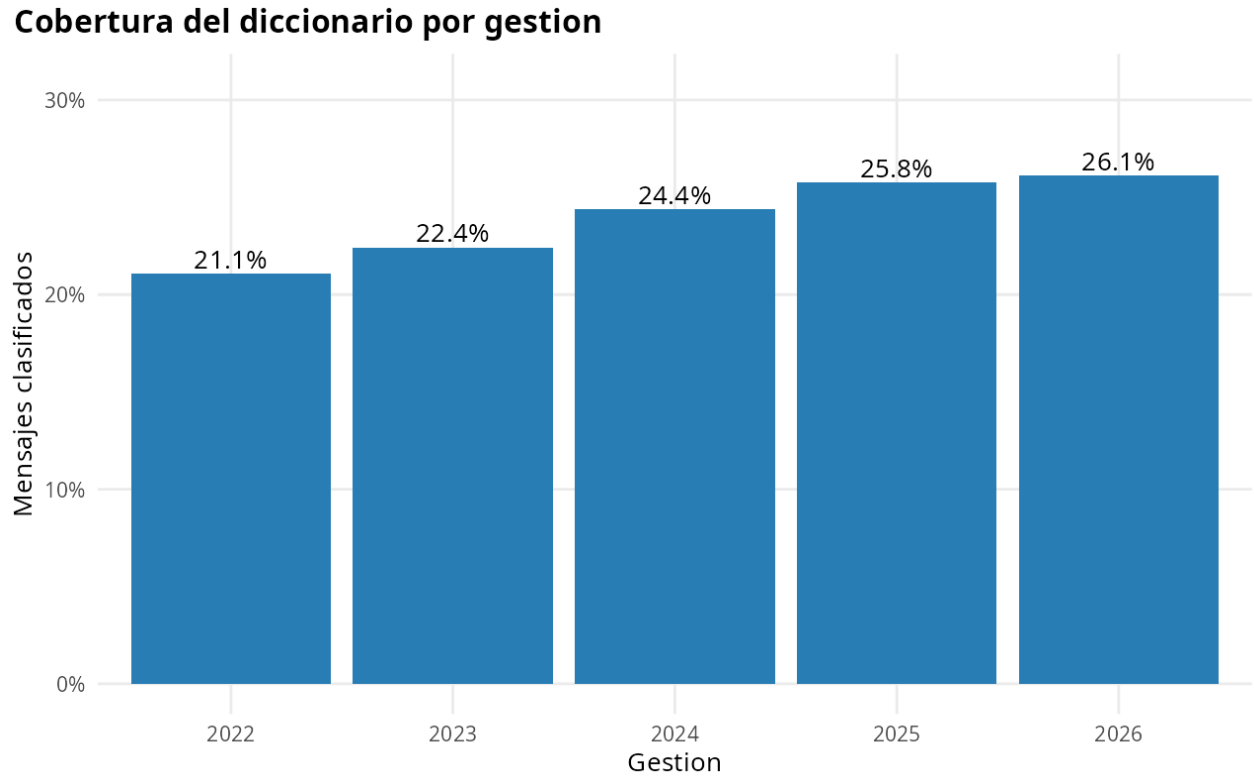
Tokens frecuentes generados con el flujo de preprocesamiento.



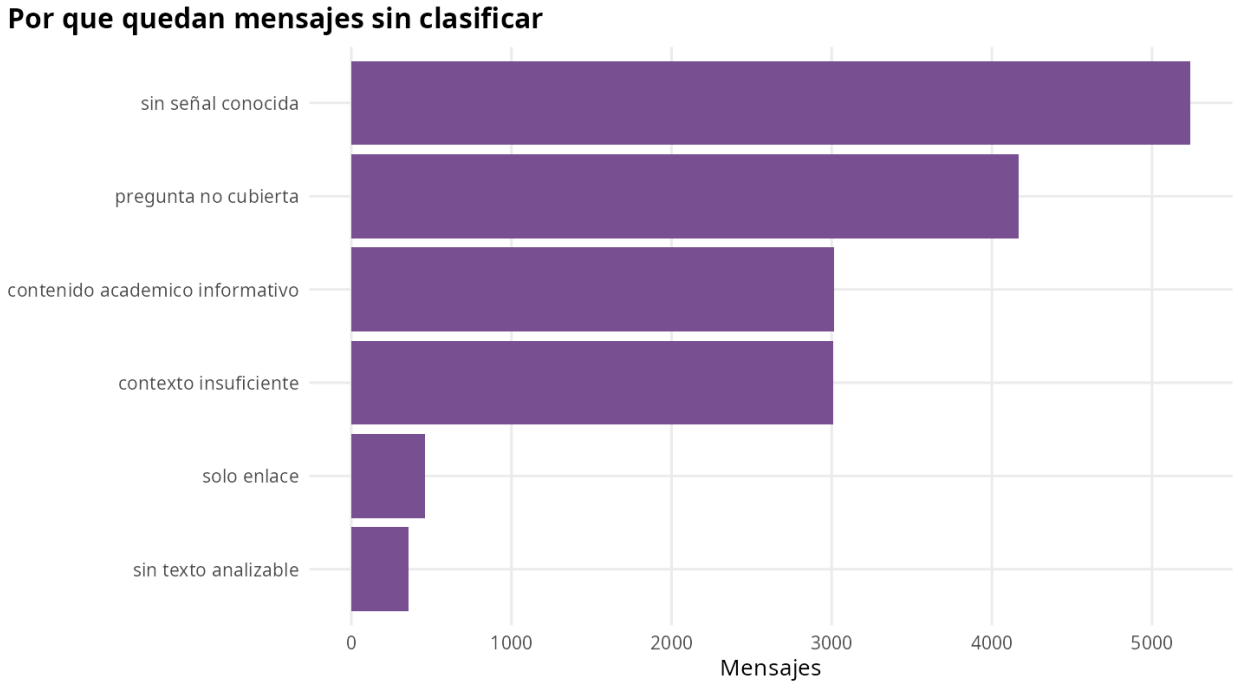
Puntaje auxiliar con syuzhet y léxico personalizado.



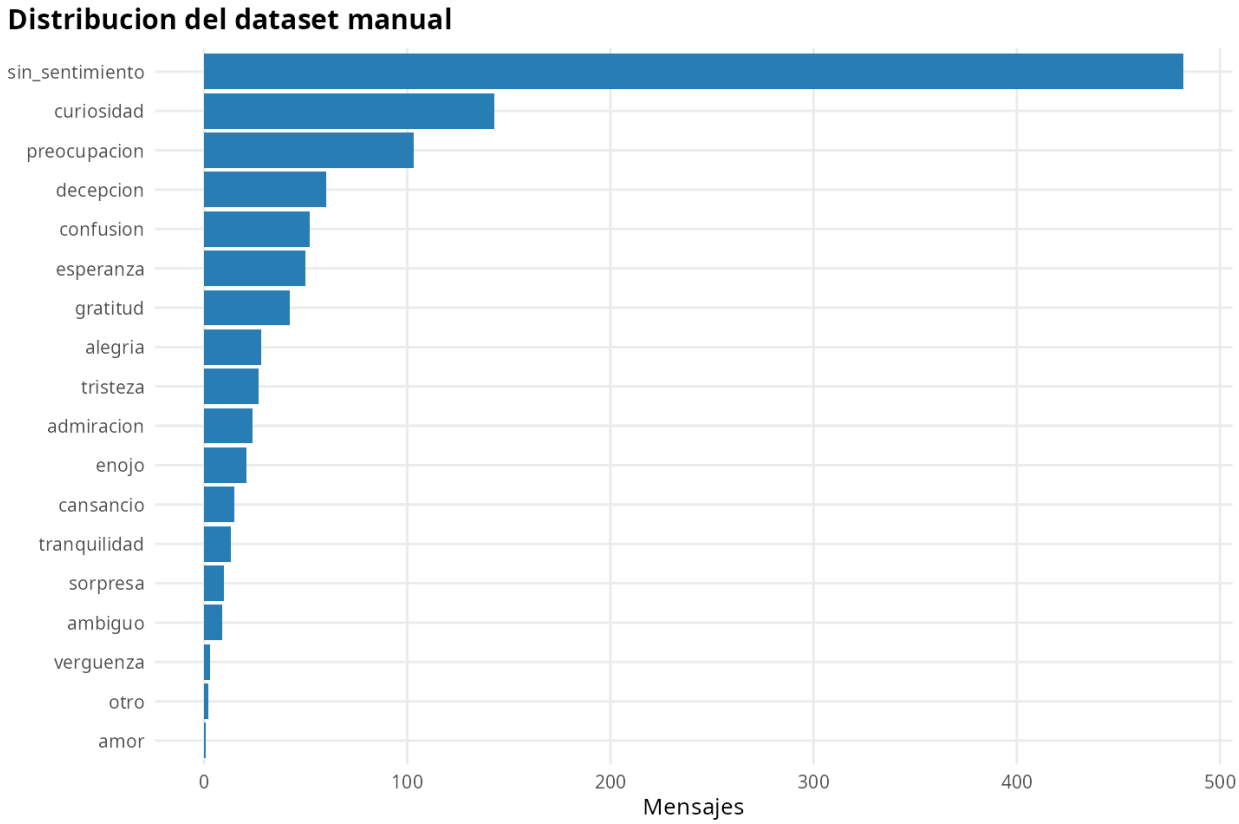
Cobertura del diccionario contextual por gestión.



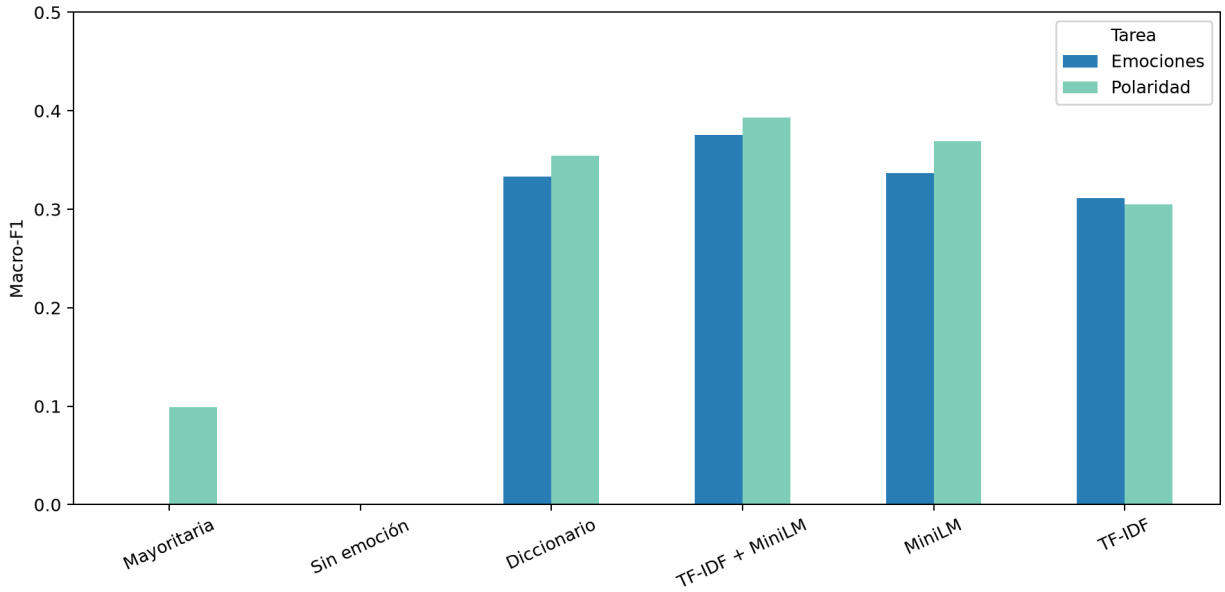
Diagnóstico de mensajes que no activaron las reglas.



Distribución del dataset humano utilizado en la etapa descriptiva.



Comparación final de modelos mediante predicciones fuera de muestra.

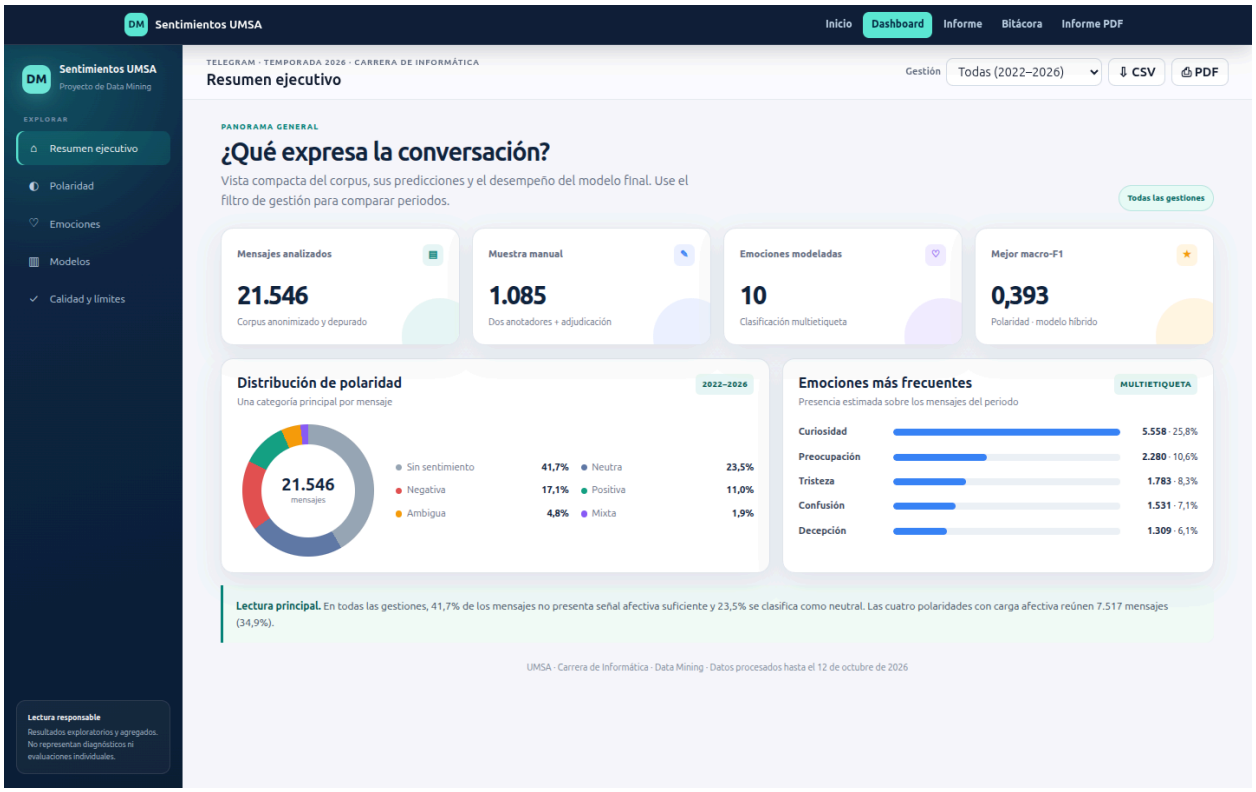


Pantalla de Inicio de la página

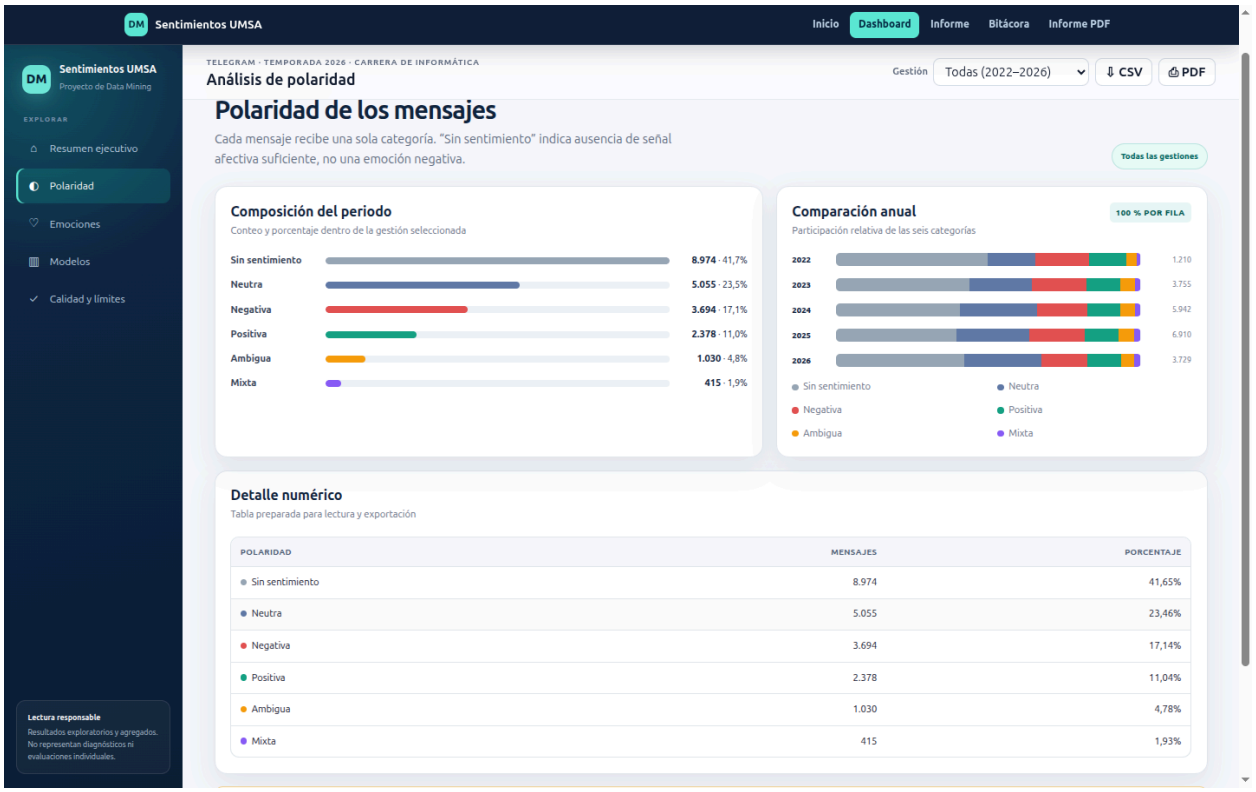


Dashboard de la página

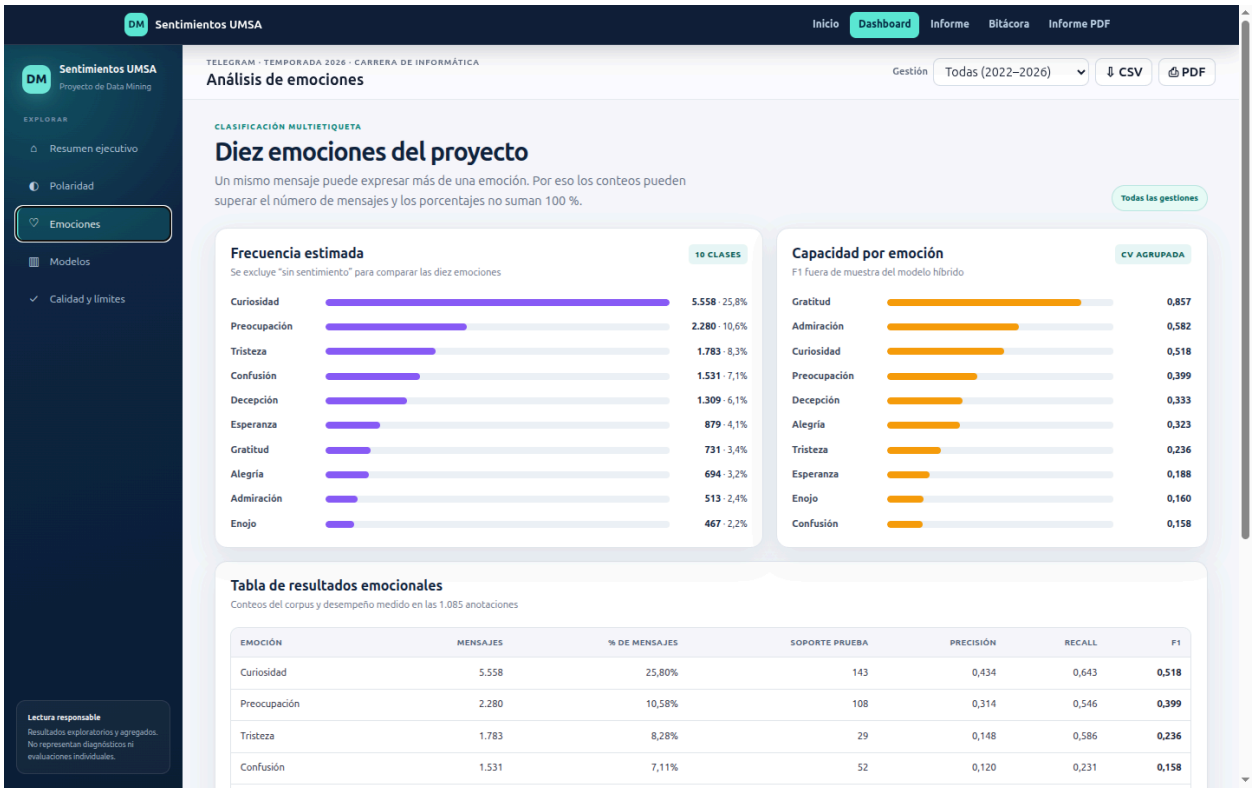
Resumen ejecutivo



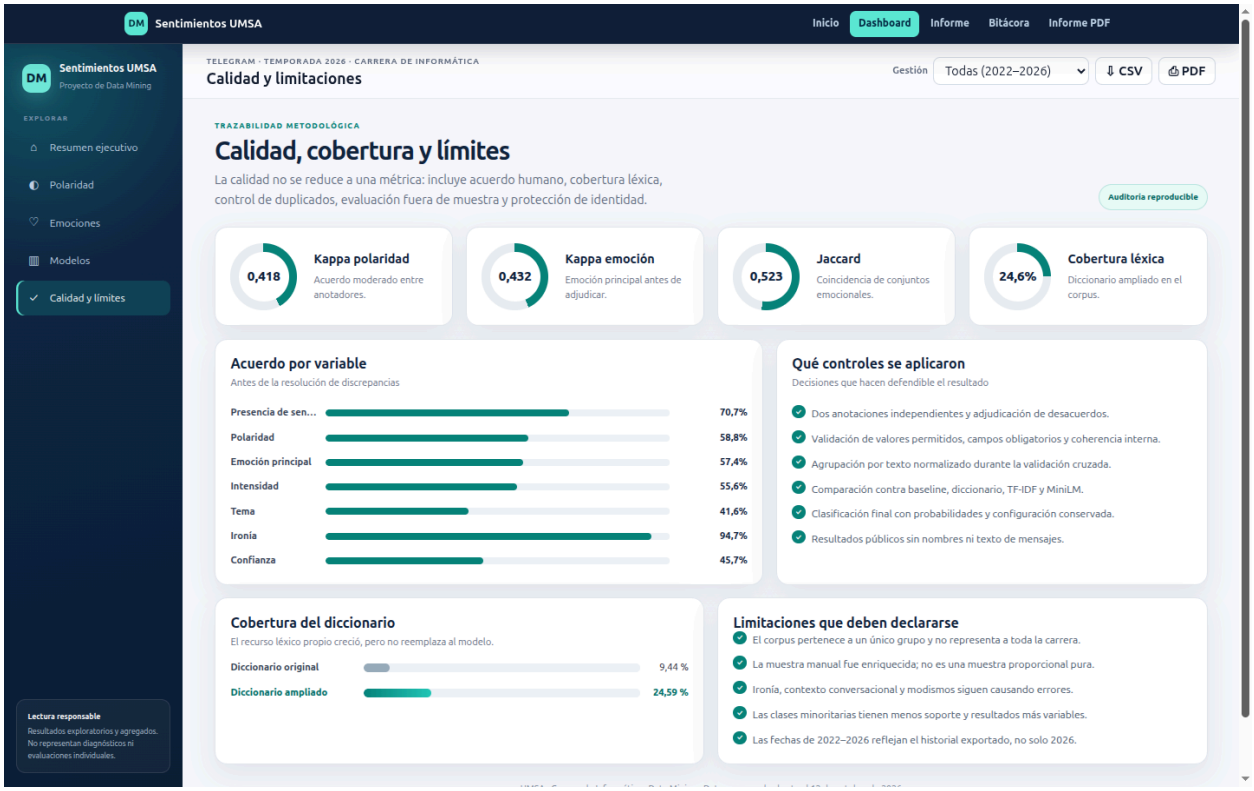
Polaridad



Modelos



Calidad y Límite



Referencias

- Benoit, K., Watanabe, K., Wang, H., Nulty, P., Obeng, A., Müller, S. y Matsuo, A. (2018). *quanteda: An R package for the quantitative analysis of textual data*. Journal of Open Source Software, 3(30), 774.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*.
- Cohen, J. (1960). *A coefficient of agreement for nominal scales*. Educational and Psychological Measurement, 20(1), 37–46.
- Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- Reimers, N. y Gurevych, I. (2019). *Sentence-BERT: Sentence embeddings using Siamese BERT-networks*. Proceedings of EMNLP-IJCNLP.
- Silge, J. y Robinson, D. (2017). *Text Mining with R: A Tidy Approach*. O'Reilly Media.

Anexo: correspondencia entre scripts y etapas

Script	Etapa	Resultado principal
`01_ejecutar_analisis.R`	Extracción y reglas	Corpus, tablas y gráficos iniciales
`02_generar_dataset_manual.R`	Muestreo	Plantillas A/B y referencia de reglas
`03_validar_dataset_manual.R`	Control de calidad	Acuerdo, errores, consenso y desacuerdos
`04_mineria_descriptiva.R`	Descripción	Frecuencias, TF-IDF, bigramas y asociaciones
`05_preprocesamiento_librerias.R`	Evidencia de procesamiento	Tokens, DFM, stemming y syuzhet
`06_corregir_etiquetado_b.R`	Correcciones mecánicas	Etiquetas B normalizadas y auditables
`07_consolidar_adjudicaciones.R`	Objetivo final	`dataset_modelado_umsa.csv`
`08_modelo_embeddings.py`	Experimento preliminar	Benchmark inicial
`09_validacion_cruzada.py`	Evaluación final	Métricas OOF, matrices y modelo seleccionado
`10_clasificar_corpus.py`	Aplicación	Predicciones y resúmenes del corpus completo